网页

搜索

2025年10月12日 13: 33: 13 UTC

所有存档 来自域名 medium.com

会分享 △打包下载 .zip ※报告错误或滥用

●請我喝杯咖啡

搜索

登记

登录

9

会员专享故事

对话式无人机:在 Jetson Thor 上集 成视觉语言模型以实现边缘 AI

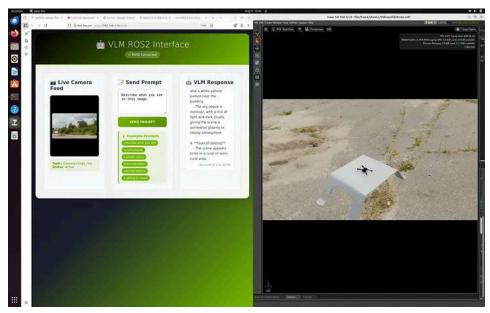


卡比兰克



5分钟阅读·10月4, 2025

63



艾萨克·西姆: 雷神上的无人机和 VLM 特工

想象一下这样一个世界,您可以与无人机交谈,它可以实时理解、观察和响应——所有这些都由边缘的尖端人工智能提供支持。这正是我们使用 Jetson Thor 和 Qwen/Qwen2.5-VL-32B-Instruct-AWQ 视觉语言模型 (VLM) 在这个硬件在环设置中构建的内容。

实时自然交互

在我们的演示中,无人机不仅仅是盲目飞行。你可以问它这样的问题:

➡ "有森林火灾吗?"

无人机使用其机载传感器观察模拟环境,然后利用 Qwen2.5-VL 模型分析它所看到的内容并生成详细的、类似人类的描述——所有这些都在 Jetson Thor 上本地处理。没有云连接,没有延迟 - 只有边缘的实时智能。

这个怎么运作

1. 硬件在环模拟

无人机在模仿真实世界条件的 Isaac Sim 模拟环境中运行。这样可以安全地测试高级人工智能功能。

2. 视觉-语言模型分析 Qwen2.5-VL模型解释无人机拍摄的图像并生成自然语言响应,将视觉和语言无缝连接。

3. 边缘 AI 处理Jetson

Thor 在本地处理所有计算,提供低延迟、高性能的推理,适用于毫秒级的现实场景。

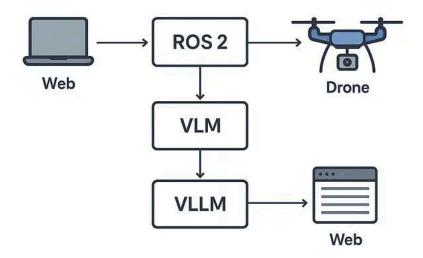
为什么这很重要

该演示不仅仅是一个技术展示,它还指向了自主系统的未来:

- 灾难响应: 快速识别火灾、洪水或其他危险并传递可作的信息。
- 环境监测: 实时跟踪野生动物、森林砍伐或污染。
- 安全作:增强通信延迟可能代价高昂的关键任务的态势感知能力。

推出边缘 AI VLM 无人机系统

要运行由 Jetson Thor 提供支持的无人机与 Qwen2.5-VL-32B-Instruct-AWQ 视觉语言模型交互的演示,您需要在单独的终端中启动多个组件。以下是分步指南:



蓝图

在 Jetson Thor 上启动边缘 AI VLM 无人机系统(带 Docker)

要运行由 Jetson Thor 提供支持的无人机与 Qwen2.5-VL-32B-Instruct-AWQ 视觉语言模型交互的演示,您需要启动多个组件。您可以本机执行此作,也可以将 Docker 用于隔离环境。

◎ (可选) 启动 Docker 容器

这可确保正确设置所有依赖项。替换为您的 Docker 镜像名称: vllm-ros2-image

```
sudo docker run --gpus all --rm -it \
    --ipc=host \
    --net=host \
    -v ~/ros2_ws:/root/ros2_ws \
    --name vllm-ros2-container \
    vllm-ros2-image:dev
```

进入容器后, 您可以像往常一样运行以下所有命令。

自动 ROSBridge (WebSocket 接口)

这允许 Web 客户端与 ROS2 主题进行通信:

```
ros2 launch rosbridge_server rosbridge_websocket_launch.xml
```

2 启动相机桥

该节点将模拟图像转换为 Web 界面可用的格式:

```
ros2 run vlm_ros2_package simple_camera_bridge
```

3 启动 VLM 客户端节点

VLM 客户端处理发送查询和处理文本响应:

```
ros2 run vlm_ros2_package vlm_client_node
```

🚹 启动 Web 界面

启动基于 Web 的界面,以便您可以通过浏览器与无人机交互:

```
cd ~/ros2_ws/src/vlm_ros2_package/web_interface
python app.py
```

5 启动 VLLM VLM 服务器

最后,使用 Qwen2.5-VL 模型启动视觉语言模型服务器:

./run_vllm_vlm_serve.sh Qwen/Qwen2.5-VL-32B-Instruct-AWQ

完善!基于此,以下是我们为什么使用 vLLM 进行推理的 Medium 就绪解释,以清晰简洁的方式集成您的详细信息:

5 启动 VLLM VLM 服务器

./run_vllm_vlm_serve.sh Qwen/Qwen2.5-VL-32B-Instruct-AWQ

我们使用 vLLM 来服务视觉语言模型 (VLM),因为它是一个快速、灵活、高效的 LLM 推理和服务库,专为大型模型设计。这就是为什么它是边缘人工智能机器人的理想选择:

1. 高性能推理:

vLLM 使用优化的 CUDA 内核、FlashAttention 和推测解码提供最先进的 吞吐量和低延迟执行,非常适合实时无人机交互。

2. 内存效率:

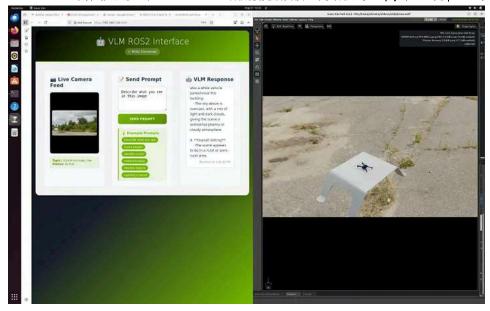
PagedAttention 和量化(GPTQ、AWQ、INT4/INT8/FP8)等先进技术允许像 Qwen2.5-VL-32B 这样的大型模型在有限的 GPU 内存上运行,例如 Jetson Thor。

3. 灵活性和兼容性:

它与 **HuggingFace** 模型无缝集成,支持流媒体输出、OpenAI 兼容 API,并可跨各种硬件平台工作,包括 NVIDIA GPU、AMD GPU、Intel CPU/GPU,甚至 TPU。

vLLM 使您的无人机(或任何机器人)能够处理视觉输入、生成自然语言响应 并实时智能地行动,同时在边缘设备上高效运行。

☑ 在所有终端(或容器步骤)运行后,您的无人机就可以完全运行了——它可以观察环境,使用 VLM 处理查询,并实时提供自然语言响应。



启动系统后

- 一旦所有终端(或 Docker 步骤)都运行完毕,您的无人机就可以完全运行了——它可以观察环境,使用 VLM 处理查询,并实时提供自然语言响应。
- ₹ 超越无人机:此演示不仅限于无人机。同样的方法可以应用于不同类型的机器人,使它们能够看到世界、理解世界并根据观察采取智能行动。

结论

通过将 Isaac Sim 中的硬件在环仿真与 Jetson Thor 和视觉语言模型集成在一起,该演示展示了用于自主无人机的逼真、安全和高性能的测试环境。该系统允许无人机感知其环境、理解复杂场景并实时智能响应——所有这些都在边缘本地处理。

这种方法不仅加速了先进机器人算法的开发和验证,还凸显了可扩展、智能自主系统的潜力。无论是无人机还是其他机器人平台,将仿真、边缘人工智能和 VLM 智能相结合,为更智能、更安全、更自主的机器人带来新的可能性。

英伟达 杰森 机器人 机器人 英伟达 GPU

63



英伟达大使

跟随

还没有回复



写一个回应

你有什么想法?

更多来自 Kabilankb

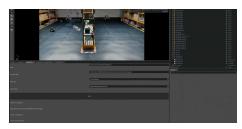




在艾萨克实验室训练SO-100立方体 提升机器人:从仿真到智能控制...

艾萨克实验室和 SO-100 立方体提升任务简介

5月1日 25



🌓 卡比兰克

在NVIDIA Isaac Sim的MobilityGen中对自定义机器人进行子类化和注册

开发自主移动机器人 (AMR) 需要大量高保 真训练数据——合成数据……

9月21 3 2

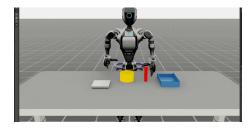




NVIDIA Jetson Nano 配备英特尔实感深度摄像头,使用 ROS2 谦虚

在本教程中,我们将探讨如何使用 ROS2 Humble 将 NVIDIA Jetson Nano 与英特尔实...

5月17, 2024 69 2



₩ 卡比兰克

Jetson AGX Thor 上的 GR00T N1: 物理 AI 的硬件在环

介绍

8月29日 4

查看卡比兰克的所有产品

从中推荐



Granite-4.0 WebGPU

A reliable and efficient AI chatbo that runs locally in your browser

You are about to load <u>Granite-4.0 Micro</u>, a 3.4B parameter long-context instruct model optimized for in-browser inference. Everything runs entirely in your browser with <u>Martansformers.js</u>



在 编码关系 由 代码包

IBM Granite 4.0:可以在本地或浏览 器中运行的小型语言模型(SLM)

Granite-4.0-Micro 模型是一个紧凑的、34亿 参数的指令模型,效率很高。

10月3日 4



🧠 在 人工智能进步 由 Himanshu Soni

我在8GBGPU上运行了一个800亿 参数的 AI 模型 - 我对 oLLM 的体验

作为一个为我的项目创建人工智能相关内容并 尝试新工具的人, 我想探索大型语言模型...

5天前 157 3





☞ 在 SDG集团 由 贡萨洛·萨巴拉

在事件驱动场景中使用 MCP 进行代 理文档分类 — 架构概述

在过去的几个月里,我一直在做一个实验项 目:将事件驱动处理 (Kafka) 与MCP服务...

10月3日 2

≥彻底改变大上下文 LLM 推理:深入探讨 oLLM Python 库





🕠 Linux 指南

设计人工智能和机器人技术以及未来 的可能性

人工智能和机器人技术的融合代表了工程领域 的变革前沿,突破了工程领域的界限.....

9月7

》为什么银行和区块链在暗中押注 Rust

在口袋里的数据科学由 赛迪拉吉·古马迪

Revolutionizing Large-Context LLM Inference: A Deep Dive into...

In the rapidly evolving world of AI, running large language models (LLMs) with massive...

Oct 1 64 2

語法野蛮人

Why Banks and Blockchains Are **Secretly Betting on Rust**

And why the language you thought was "just for systems programming" is quietly rewritin...

Sep 4 49 2

See more recommendations